

# Phân cụm Dữ liệu trong Học máy

## Bản chất, Các lớp Thuật toán Trọng yếu & Đánh giá Mô hình

TS. Vũ Đức Minh

Khoa Khoa học Dữ liệu và Trí tuệ Nhân tạo  
Trường Công nghệ và Kinh tế số - Đại học Kinh tế Quốc dân (NEU)

2026


## Mục tiêu Bài học (Learning Objectives)

- **Bản chất Phân cụm (Clustering):** Hiểu rõ triết lý Học không giám sát (Unsupervised Learning) và phân biệt rạch ròi **Hard Clustering** vs **Soft Clustering**.
- **Làm chủ 4 trường phái thuật toán cốt lõi:**
  - 1 **Centroid-based:** K-Means, K-Means++, Elbow Method.
  - 2 **Connectivity-based:** Hierarchical Clustering, Agglomerative, Dendrogram, Linkage Criteria.
  - 3 **Density-based:** DBSCAN (Core/Border/Noise, K-distance graph), OPTICS (Reachability Plot).
  - 4 **Distribution-based:** Gaussian Mixture Models (GMM), Thuật toán Expectation-Maximization (EM).
- **Đánh giá Chất lượng Mô hình:** Áp dụng các chỉ số nội tại (Silhouette Coefficient, Davies-Bouldin) và tiêu chuẩn thông tin (AIC/BIC).
- **Lựa chọn Thuật toán:** Ra quyết định kiến trúc phù hợp với đặc thù hình thái dữ liệu thực tế.

# 1. Bản chất của Phân cụm Dữ liệu (Clustering)

## Khái niệm nền tảng:


- Là bài toán trung tâm của **Học không giám sát (Unsupervised Learning)**.
- Dữ liệu đầu vào chỉ có các biến đặc trưng  $\mathcal{X} = \{x_1, \dots, x_N\}$ , **không có nhãn mục tiêu**  $y$ .
- **Mục tiêu tối thượng:** Tự động gom các quan sát vào các nhóm (cụm) sao cho:
  - **Độ tương đồng nội cụm cao nhất** (High intra-cluster similarity).
  - **Độ phân tách ngoại cụm lớn nhất** (High inter-cluster dissimilarity).



# Phân loại Hình thức: Hard Clustering vs Soft Clustering

## 1. Phân cụm cứng (Hard Clustering):

- Mỗi điểm  $x_i$  thuộc duy nhất về một cụm  $C_k$  với xác suất tuyệt đối 100%.
- Nhãn phân cụm nhị phân:  $z_{ik} \in \{0, 1\}$ .
- Đại diện tiêu biểu: K-Means, Hierarchical, DBSCAN.



## 2. Phân cụm mềm (Soft / Fuzzy Clustering):

- Mỗi điểm thuộc về tất cả các cụm với một **trọng số xác suất**  $\gamma_{ik} \in [0, 1]$  thỏa mãn  $\sum_{k=1}^K \gamma_{ik} = 1$ .
- Đại diện tiêu biểu: GMM (EM), Fuzzy C-Means

# Bức tranh Toàn cảnh: 5 Trường phái Phân cụm Chính

| Trường phái           | Triết lý Gom cụm                                 | Thuật toán Tiêu biểu             | Đặc trưng Hình học                       |
|-----------------------|--------------------------------------------------|----------------------------------|------------------------------------------|
| <b>Centroid-based</b> | Đại diện cụm bằng một tâm điểm trung tâm         | K-Means, Means++, Medoids        | Hình cầu lồi (Spherical), ô Voronoi      |
| <b>Connectivity</b>   | Dựa trên khoảng cách lân cận giữa các mẫu        | Agglomerative, Divisive, BIRCH   | Cây phân cấp đa tầng (Dendrogram)        |
| <b>Density-based</b>  | Cụm là vùng mật độ cao cách biệt bởi vùng thưa   | DBSCAN, OPTICS, HDBSCAN          | Hình dạng tùy ý, tự động lọc nhiễu       |
| <b>Distribution</b>   | Dữ liệu sinh ra từ tổ hợp các phân phối xác suất | Gaussian Mixture Model (GMM), EM | Hình Elip tự do, xác suất thành viên mềm |
| <b>Grid / Fuzzy</b>   | Lưới không gian hoặc mức độ mờ                   | STING, CLIQUE, Fuzzy C-Means     | Khối lưới, độ thuộc mờ                   |

## 2. Centroid-based: Thuật toán K-Means Cổ điển

### Quy trình 4 bước của Lloyd (1957):


- 1 **Khởi tạo:** Chọn ngẫu nhiên  $K$  tâm cụm  $\mu_1, \dots, \mu_K$ .
- 2 **Gán cụm (Assignment):** Gán mỗi điểm  $x_i$  vào cụm có tâm gần nhất:

$$c^{(i)} = \arg \min_k \|x_i - \mu_k\|_2^2$$

- 3 **Cập nhật tâm (Update):** Tính lại tọa độ trọng tâm:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

- 4 **Lặp lại** bước 2 và 3 cho đến khi tâm không đổi.



# Centroid-based: K-Means++ và Phương pháp Khuỷu tay


## K-Means++ (Arthur & Vassilvitskii, 2007):

- Khởi tạo tâm ngẫu nhiên để rơi vào **cực tiểu cục bộ kém**.
- K-Means++ chọn tâm tiếp theo với xác suất tỷ lệ thuận với bình phương khoảng cách tới tâm gần nhất:

$$P(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2}$$

- **Đảm bảo lý thuyết:** Kỳ vọng nghiệm đạt xấp xỉ  $O(\log K)$  so với tối ưu toàn cục.

## Phương pháp Khuỷu tay (Elbow Method):



- Vẽ đồ thị Inertia (WCSS) theo số cụm  $K$ .
- Chọn  $K$  tại **điểm gãy (Elbow)** nơi tốc độ giảm WCSS bắt đầu chững /18


### 3. Connectivity-based: Phân cụm Phân cấp (Hierarchical)

#### Hai hướng tiếp cận đối xứng:

- **Agglomerative (Bottom-Up):** Đi từ  $N$  cụm đơn lẻ  $\rightarrow$  liên tục sáp nhập 2 cụm gần nhất  $\rightarrow$  1 cụm tổng thể ( $N - 1$  bước).
- **Divisive (Top-Down):** Đi từ 1 cụm lớn  $\rightarrow$  liên tục phân tách đệ quy  $\rightarrow N$  cụm đơn lẻ.

#### Ưu điểm đột phá:


- **Không cần chọn trước số cụm  $K$ .**
- Cho phép phân tích cấu trúc đa tầng lồng nhau (Nested Hierarchy).



# Biểu đồ Cây Phân cấp (Dendrogram) & Cắt Cây Tìm $K$

## What is Hierarchical Clustering

Hierarchical clustering is an unsupervised machine learning algorithm that groups data into a tree of nested clusters



## Quy tắc Cắt cây tìm $K$ tối ưu:

- 1 Tìm **nhánh thẳng đứng dài nhất** mà không bị bất kỳ đường ngang nào cắt qua.
- 2 Vẽ một đường cắt nằm ngang xuyên qua khoảng trống này.
- 3 **Số lượng cụm  $K$  tối ưu** chính là số lượng nhánh dọc bị đường thẳng này cắt qua!

*Ý nghĩa:* Khoảng cách dọc lớn chứng tỏ cấu trúc cụm giữ nguyên trạng thái phân tách ổn định trên một khoảng khoảng cách rộng.

# Các Tiêu chuẩn Liên kết Cụm (Linkage Criteria)

## Distance Metrics in Hierarchical Clustering



Minimum Distance



Maximum Distance



Group Average



Ward's Method

- **Single Linkage (Min):**  $\min d(x, z)$ . Nhận diện cụm phi cầu tốt, nhưng dễ mắc **Hiện tượng Nối chuỗi (Chaining Effect)**.
- **Complete Linkage (Max):**  $\max d(x, z)$ . Tạo cụm tròn đặc, ngăn nối chuỗi nhưng nhạy cảm với ngoại lai.
- **Average Linkage (UPGMA):** Trung bình cộng khoảng cách cặp đôi. Cân bằng, đạt hệ số Cophenetic (CPCC) cao.
- **Centroid Linkage:**  $\|\mu_A - \mu_B\|$ . Dễ bị **Hiện tượng Đảo ngược (Inversion)** phá vỡ tính đơn điệu.
- **Ward's Method:** Tối thiểu hóa mức tăng tổng phương sai nội cụm  $\Delta WCSS$ . Tạo cụm đều, đẹp nhất cho dữ liệu chuẩn.


## 4. Density-based: Thuật toán DBSCAN

**Hai siêu tham số:** Bán kính  $\epsilon$  và MinPts.

**Phân loại 3 nhóm điểm:**


- **Core Point:**  $|N_{\epsilon}(p)| \geq \text{MinPts}$ .
- **Border Point:**  $|N_{\epsilon}(p)| < \text{MinPts}$  nhưng nằm trong bán kính  $\epsilon$  của một Core Point.
- **Noise Point:** Không thuộc 2 nhóm trên (gán nhãn **-1**).

**Cơ chế lan truyền cụm:** Liên thông mật độ thông qua các chuỗi điểm tiếp cận trực tiếp.




# DBSCAN Đồ thị K-Distance & Thuật toán OPTICS

## Tìm $\epsilon$ bằng Đồ thị K-Distance:



Sắp xếp khoảng cách đến láng giềng thứ  $k = \text{MinPts} - 1$ , điểm uốn cong (Knee) là  $\epsilon$  chuẩn.

## OPTICS: Khắc phục Đa mật độ:



- Tính **Core Distance** & **Reachability Distance**.

- Biểu đồ **Reachability Plot**: Thung lũng = Cụm, Đỉnh núi = Ranh giới/Nhiều.

- Trích xuất tự động qua hệ số dốc  $\xi$ . 12/18

## 5. Distribution-based: Gaussian Mixture Models (GMM)


### Mô hình xác suất tạo sinh (Generative Model):

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

- $\pi_k$ : Trọng số thành phần ( $\sum \pi_k = 1$ ).
- $\mu_k$ : Vector kỳ vọng (tâm cụm).
- $\Sigma_k$ : Ma trận hiệp phương sai (hình dạng elip).

### Phân cụm mềm (Soft Assignment):

$$\gamma_{nk} = P(z_{nk} = 1 | x_n) = \frac{\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)}$$



# Thuật toán Expectation-Maximization (EM) & Ma trận Hiệp phương sai


## Hai bước luân phiên của EM:

- **E-step:** Tính ma trận trách nhiệm  $\gamma_{nk}$  theo tham số hiện tại.
- **M-step:** Cập nhật tham số theo trung bình có trọng số:

$$\mu_k = \frac{1}{N_k} \sum \gamma_{nk} \mathbf{x}_n, \quad \pi_k = \frac{N_k}{N}$$

$$\Sigma_k = \frac{1}{N_k} \sum \gamma_{nk} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

**Bảo đảm toán học:** Hàm Log-Likelihood luôn tăng đơn điệu sau mỗi epoch!



## 4 Dạng ma trận hiệp phương sai:

- spherical: Hình cầu, đẳng hướng.
- diag: Elip song song các trục tọa độ.
- tied: Các cụm chia sẻ chung 1 ma trận.
- full: Elip tự do mọi hướng (tổng quát).

## 6. Đánh giá Chất lượng Phân cụm (Clustering Metrics)

**Khi KHÔNG có nhãn thực tế (Internal):**      **Khi CÓ nhãn đối chuẩn (External):**

- **Silhouette Coefficient ( $s \in [-1, 1]$ ):**

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

$a(i)$ : khoảng cách nội cụm trung bình;  
 $b(i)$ : khoảng cách tới cụm gần nhất.  
 $s > 0.5 \Rightarrow$  Tốt.

- **Davies-Bouldin Index (DBI):** Tỷ số giữa độ phân tán nội cụm và khoảng cách liên cụm. **Càng nhỏ càng tốt.**
- **Calinski-Harabasz Index:** Tỷ số phương sai liên cụm / nội cụm. **Càng lớn càng tốt.**

- **Adjusted Rand Index (ARI):** Đo tỷ lệ cặp điểm được gán cùng nhóm, khử yếu tố ngẫu nhiên ( $-1 \leq \text{ARI} \leq 1$ ).
- **Normalized Mutual Information (NMI):** Tương hỗ thông tin chuẩn hóa giữa nhãn thực và nhãn dự báo ( $0 \leq \text{NMI} \leq 1$ ).

**Chọn mô hình xác suất (GMM):**


$$\text{BIC} = -2 \ln L + p \ln N \rightarrow \min$$

$$\text{AIC} = -2 \ln L + 2p \rightarrow \min$$

# Bảng So sánh Tổng hợp 5 Trường phái Thuật toán

| Tiêu chí                                                                  | K-Means                                           | Hierarchical                                 | DBSCAN                                                        | OPTICS                                                                   | GMM (EM)                                                       |
|---------------------------------------------------------------------------|---------------------------------------------------|----------------------------------------------|---------------------------------------------------------------|--------------------------------------------------------------------------|----------------------------------------------------------------|
| <b>Loại phân cụm</b><br><b>Cần chọn trước K?</b><br><b>Hình thái cụm</b>  | Cứng (Hard)<br><b>Bắt buộc</b><br>Hình cầu lõi    | Cứng (Hard)<br>Không<br>Hình cầu / Linh hoạt | Cứng (Hard)<br>Không<br><b>Bất kỳ (Phi tuyến)</b>             | Cứng (Hard)<br>Không<br><b>Bất kỳ (Phi tuyến)</b>                        | <b>Mềm (Soft)</b><br><b>Bắt buộc</b><br><b>Hình Elip tự do</b> |
| <b>Cụm đa mật độ</b><br><b>Xử lý ngoại lai</b><br><b>Độ phức tạp Time</b> | Kém<br>Kém (bị kéo tâm)<br>$O(N \cdot K \cdot I)$ | Trung bình<br>Kém<br>$O(N^2 \log N)$         | Kém<br><b>Tự động lọc</b><br>$O(N \log N) \rightarrow O(N^2)$ | <b>Rất tốt</b><br><b>Tự động lọc</b><br>$O(N \log N) \rightarrow O(N^2)$ | Tốt<br>Trung bình<br>$O(N \cdot K \cdot I \cdot d^3)$          |
| <b>Độ phức tạp Space</b><br><b>Đầu ra trực quan</b>                       | $O(N \cdot d)$<br>Tâm cụm, Voronoi                | $O(N^2)$<br>Dendrogram                       | $O(N)$<br>Nhấn cụm phẳng                                      | $O(N)$<br>Reachability Plot                                              | $O(N \cdot d + K \cdot d^2)$<br>Elip tin cậy                   |

# Cây Quyết định Lựa chọn Thuật toán trong Thực tế



# Tổng kết & Lộ trình Thực hành Lab

## Tóm tắt bài học:

- Phân cụm là công cụ khám phá cấu trúc tự nhiên mạnh mẽ nhất của Khoa học Dữ liệu.
- Không có một thuật toán duy nhất tối ưu cho mọi bài toán (*No Free Lunch Theorem*).
- Lựa chọn thuật toán phụ thuộc chặt chẽ vào:
  - Kích thước dữ liệu  $N$  (Scale).
  - Hình thái hình học của cụm.
  - Tỷ lệ nhiễu và ngoại lai.
  - Yêu cầu bài toán kinh doanh (cứng hay mềm).

## Nội dung Thực hành trong Notebook:

### ① Bài tập tính tay (Hand Calculations):

- 1 vòng lặp K-Means trên tập số liệu mẫu.
- Sáp nhập Single/Complete Linkage.
- Phân loại Core/Border/Noise trong DBSCAN.
- 1 chu kỳ E-step & M-step trong GMM.

### ② Bài tập Điền khuyết Code (Fill-in-the-Blank):

- Hoàn thiện code Scikit-Learn.
- Tự động chấm điểm (Assert test)