

Phân cụm Dữ liệu trong Học máy

Bản chất, Các lớp Thuật toán Trọng yếu & Đánh giá Mô hình

TS. Vũ Đức Minh

Khoa Khoa học Dữ liệu và Trí tuệ Nhân tạo
Trường Công nghệ - Đại học Kinh tế Quốc dân (NEU)

2026


Mục tiêu Bài học (Learning Objectives)

- **Bản chất Phân cụm (Clustering):** Hiểu rõ triết lý Học không giám sát (Unsupervised Learning) và phân biệt rạch ròi **Hard Clustering** vs **Soft Clustering**.
- **Làm chủ 4 trường phái thuật toán cốt lõi:**
 - 1 **Centroid-based:** K-Means, K-Means++, Elbow Method.
 - 2 **Connectivity-based:** Hierarchical Clustering, Agglomerative, Dendrogram, Linkage Criteria.
 - 3 **Density-based:** DBSCAN (Core/Border/Noise, K-distance graph), OPTICS (Reachability Plot).
 - 4 **Distribution-based:** Gaussian Mixture Models (GMM), Thuật toán Expectation-Maximization (EM).
- **Đánh giá Chất lượng Mô hình:** Áp dụng các chỉ số nội tại (Silhouette Coefficient, Davies-Bouldin) và tiêu chuẩn thông tin (AIC/BIC).
- **Lựa chọn Thuật toán:** Ra quyết định kiến trúc phù hợp với đặc thù hình thái dữ liệu thực tế.

1. Bản chất của Phân cụm Dữ liệu (Clustering)

Khái niệm nền tảng:


- Là bài toán trung tâm của **Học không giám sát (Unsupervised Learning)**.
- Dữ liệu đầu vào chỉ có các biến đặc trưng $\mathcal{X} = \{x_1, \dots, x_N\}$, **không có nhãn mục tiêu** y .
- **Mục tiêu tối thượng:** Tự động gom các quan sát vào các nhóm (cụm) sao cho:
 - **Độ tương đồng nội cụm cao nhất** (High intra-cluster similarity).
 - **Độ phân tách ngoại cụm lớn nhất** (High inter-cluster dissimilarity).



Phân loại Hình thức: Hard Clustering vs Soft Clustering

1. Phân cụm cứng (Hard Clustering):

- Mỗi điểm x_i thuộc duy nhất về một cụm C_k với xác suất tuyệt đối 100%.
- Nhãn phân cụm nhị phân: $z_{ik} \in \{0, 1\}$.
- Đại diện tiêu biểu: K-Means, Hierarchical, DBSCAN.



2. Phân cụm mềm (Soft / Fuzzy Clustering):

- Mỗi điểm thuộc về tất cả các cụm với một **trọng số xác suất** $\gamma_{ik} \in [0, 1]$ thỏa mãn $\sum_{k=1}^K \gamma_{ik} = 1$.
- Đại diện tiêu biểu: GMM (EM), Fuzzy C-Means

Bức tranh Toàn cảnh: 5 Trường phái Phân cụm Chính

Trường phái	Triết lý Gom cụm	Thuật toán Tiêu biểu	Đặc trưng Hình học
Centroid-based	Đại diện cụm bằng một tâm điểm trung tâm	K-Means, Means++, Medoids	Hình cầu lồi (Spherical), ô Voronoi
Connectivity	Dựa trên khoảng cách lân cận giữa các mẫu	Agglomerative, Divisive, BIRCH	Cây phân cấp đa tầng (Dendrogram)
Density-based	Cụm là vùng mật độ cao cách biệt bởi vùng thưa	DBSCAN, OPTICS, HDBSCAN	Hình dạng tùy ý, tự động lọc nhiễu
Distribution	Dữ liệu sinh ra từ tổ hợp các phân phối xác suất	Gaussian Mixture Model (GMM), EM	Hình Elip tự do, xác suất thành viên mềm
Grid / Fuzzy	Lưới không gian hoặc mức độ mờ	STING, CLIQUE, Fuzzy C-Means	Khối lưới, độ thuộc mờ

2. Centroid-based: Thuật toán K-Means Cổ điển

Quy trình 4 bước của Lloyd (1957):


- 1 **Khởi tạo:** Chọn ngẫu nhiên K tâm cụm $\mu_1, \dots, \mu_K$.
- 2 **Gán cụm (Assignment):** Gán mỗi điểm x_i vào cụm có tâm gần nhất:

$$c^{(i)} = \arg \min_k \|x_i - \mu_k\|_2^2$$

- 3 **Cập nhật tâm (Update):** Tính lại tọa độ trọng tâm:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

- 4 **Lặp lại** bước 2 và 3 cho đến khi tâm không đổi.



Centroid-based: K-Means++ và Phương pháp Khuỷu tay


K-Means++ (Arthur & Vassilvitskii, 2007):

- Khởi tạo tâm ngẫu nhiên để rơi vào **cực tiểu cục bộ kém**.
- K-Means++ chọn tâm tiếp theo với xác suất tỷ lệ thuận với bình phương khoảng cách tới tâm gần nhất:

$$P(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2}$$

- **Đảm bảo lý thuyết:** Kỳ vọng nghiệm đạt xấp xỉ $O(\log K)$ so với tối ưu toàn cục.

Phương pháp Khuỷu tay (Elbow Method):



- Vẽ đồ thị Inertia (WCSS) theo số cụm K .
- Chọn K tại **điểm gãy (Elbow)** nơi tốc độ giảm WCSS bắt đầu chững /18


3. Connectivity-based: Phân cụm Phân cấp (Hierarchical)

Hai hướng tiếp cận đối xứng:

- **Agglomerative (Bottom-Up):** Đi từ N cụm đơn lẻ $\rightarrow$ liên tục sáp nhập 2 cụm gần nhất $\rightarrow$ 1 cụm tổng thể ($N - 1$ bước).
- **Divisive (Top-Down):** Đi từ 1 cụm lớn $\rightarrow$ liên tục phân tách đệ quy $\rightarrow N$ cụm đơn lẻ.

Ưu điểm đột phá:


- **Không cần chọn trước số cụm K .**
- Cho phép phân tích cấu trúc đa tầng lồng nhau (Nested Hierarchy).



Biểu đồ Cây Phân cấp (Dendrogram) & Cắt Cây Tìm K

What is Hierarchical Clustering

Hierarchical clustering is an unsupervised machine learning algorithm that groups data into a tree of nested clusters



Quy tắc Cắt cây tìm K tối ưu:

- 1 Tìm **nhánh thẳng đứng dài nhất** mà không bị bất kỳ đường ngang nào cắt qua.
- 2 Vẽ một đường cắt nằm ngang xuyên qua khoảng trống này.
- 3 **Số lượng cụm K tối ưu** chính là số lượng nhánh dọc bị đường thẳng này cắt qua!

Ý nghĩa: Khoảng cách dọc lớn chứng tỏ cấu trúc cụm giữ nguyên trạng thái phân tách ổn định trên một khoảng khoảng cách rộng.

Các Tiêu chuẩn Liên kết Cụm (Linkage Criteria)

Distance Metrics in Hierarchical Clustering



Minimum Distance



Maximum Distance



Group Average



Ward's Method

- **Single Linkage (Min):** $\min d(x, z)$. Nhận diện cụm phi cầu tốt, nhưng dễ mắc **Hiện tượng Nối chuỗi (Chaining Effect)**.
- **Complete Linkage (Max):** $\max d(x, z)$. Tạo cụm tròn đặc, ngăn nối chuỗi nhưng nhạy cảm với ngoại lai.
- **Average Linkage (UPGMA):** Trung bình cộng khoảng cách cặp đôi. Cân bằng, đạt hệ số Cophenetic (CPCC) cao.
- **Centroid Linkage:** $\|\mu_A - \mu_B\|$. Dễ bị **Hiện tượng Đảo ngược (Inversion)** phá vỡ tính đơn điệu.
- **Ward's Method:** Tối thiểu hóa mức tăng tổng phương sai nội cụm $\Delta WCSS$. Tạo cụm đều, đẹp nhất cho dữ liệu chuẩn.


4. Density-based: Thuật toán DBSCAN

Hai siêu tham số: Bán kính ϵ và MinPts.

Phân loại 3 nhóm điểm:


- **Core Point:** $|N_{\epsilon}(p)| \geq \text{MinPts}$.
- **Border Point:** $|N_{\epsilon}(p)| < \text{MinPts}$ nhưng nằm trong bán kính ϵ của một Core Point.
- **Noise Point:** Không thuộc 2 nhóm trên (gán nhãn **-1**).

Cơ chế lan truyền cụm: Liên thông mật độ thông qua các chuỗi điểm tiếp cận trực tiếp.




DBSCAN Đồ thị K-Distance & Thuật toán OPTICS

Tìm ϵ bằng Đồ thị K-Distance:



Sắp xếp khoảng cách đến láng giềng thứ $k = \text{MinPts} - 1$, điểm uốn cong (Knee) là ϵ chuẩn.

OPTICS: Khắc phục Đa mật độ:



- Tính **Core Distance** & **Reachability Distance**.

- Biểu đồ **Reachability Plot**: Thung lũng = Cụm, Đỉnh núi = Ranh giới/Nhiều.

- Trích xuất tự động qua hệ số dốc ξ . 12/18

5. Distribution-based: Gaussian Mixture Models (GMM)


Mô hình xác suất tạo sinh (Generative Model):

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

- π_k : Trọng số thành phần ($\sum \pi_k = 1$).
- μ_k : Vector kỳ vọng (tâm cụm).
- Σ_k : Ma trận hiệp phương sai (hình dạng elip).

Phân cụm mềm (Soft Assignment):

$$\gamma_{nk} = P(z_{nk} = 1 | x_n) = \frac{\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)}$$



Thuật toán Expectation-Maximization (EM) & Ma trận Hiệp phương sai


Hai bước luân phiên của EM:

- **E-step:** Tính ma trận trách nhiệm γ_{nk} theo tham số hiện tại.
- **M-step:** Cập nhật tham số theo trung bình có trọng số:

$$\mu_k = \frac{1}{N_k} \sum \gamma_{nk} \mathbf{x}_n, \quad \pi_k = \frac{N_k}{N}$$

$$\Sigma_k = \frac{1}{N_k} \sum \gamma_{nk} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

Bảo đảm toán học: Hàm Log-Likelihood luôn tăng đơn điệu sau mỗi epoch!



4 Dạng ma trận hiệp phương sai:

- spherical: Hình cầu, đẳng hướng.
- diag: Elip song song các trục tọa độ.
- tied: Các cụm chia sẻ chung 1 ma trận.
- full: Elip tự do mọi hướng (tổng quát).

6. Đánh giá Chất lượng Phân cụm (Clustering Metrics)

Khi KHÔNG có nhãn thực tế (Internal): **Khi CÓ nhãn đối chuẩn (External):**

- **Silhouette Coefficient** ($s \in [-1, 1]$):

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

$a(i)$: khoảng cách nội cụm trung bình;
 $b(i)$: khoảng cách tới cụm gần nhất.
 $s > 0.5 \Rightarrow$ Tốt.

- **Davies-Bouldin Index (DBI)**: Tỷ số giữa độ phân tán nội cụm và khoảng cách liên cụm. **Càng nhỏ càng tốt.**
- **Calinski-Harabasz Index**: Tỷ số phương sai liên cụm / nội cụm. **Càng lớn càng tốt.**

- **Adjusted Rand Index (ARI)**: Đo tỷ lệ cặp điểm được gán cùng nhóm, khử yếu tố ngẫu nhiên ($-1 \leq \text{ARI} \leq 1$).
- **Normalized Mutual Information (NMI)**: Tương hỗ thông tin chuẩn hóa giữa nhãn thực và nhãn dự báo ($0 \leq \text{NMI} \leq 1$).

Chọn mô hình xác suất (GMM):


$$\text{BIC} = -2 \ln L + p \ln N \rightarrow \min$$

$$\text{AIC} = -2 \ln L + 2p \rightarrow \min$$

Bảng So sánh Tổng hợp 5 Trường phái Thuật toán

Tiêu chí	K-Means	Hierarchical	DBSCAN	OPTICS	GMM (EM)
Loại phân cụm Cần chọn trước K? Hình thái cụm	Cứng (Hard) Bắt buộc Hình cầu lồi	Cứng (Hard) Không Hình cầu / Linh hoạt	Cứng (Hard) Không Bất kỳ (Phi tuyến)	Cứng (Hard) Không Bất kỳ (Phi tuyến)	Mềm (Soft) Bắt buộc Hình Elip tự do
Cụm đa mật độ Xử lý ngoại lai Độ phức tạp Time	Kém Kém (bị kéo tâm) $O(N \cdot K \cdot I)$	Trung bình Kém $O(N^2 \log N)$	Kém Tự động lọc $O(N \log N) \rightarrow$ $O(N^2)$	Rất tốt Tự động lọc $O(N \log N) \rightarrow$ $O(N^2)$	Tốt Trung bình $O(N \cdot K \cdot I \cdot d^3)$
Độ phức tạp Space Đầu ra trực quan	$O(N \cdot d)$ Tâm cụm, Voronoi	$O(N^2)$ Dendrogram	$O(N)$ Nhấn cụm phẳng	$O(N)$ Reachability Plot	$O(N \cdot d + K \cdot d^2)$ Elip tin cậy

Cây Quyết định Lựa chọn Thuật toán trong Thực tế



Tổng kết & Lộ trình Thực hành Lab

Tóm tắt bài học:

- Phân cụm là công cụ khám phá cấu trúc tự nhiên mạnh mẽ nhất của Khoa học Dữ liệu.
- Không có một thuật toán duy nhất tối ưu cho mọi bài toán (*No Free Lunch Theorem*).
- Lựa chọn thuật toán phụ thuộc chặt chẽ vào:
 - Kích thước dữ liệu N (Scale).
 - Hình thái hình học của cụm.
 - Tỷ lệ nhiễu và ngoại lai.
 - Yêu cầu bài toán kinh doanh (cứng hay mềm).

Nội dung Thực hành trong Notebook:

① Bài tập tính tay (Hand Calculations):

- 1 vòng lặp K-Means trên tập số liệu mẫu.
- Sáp nhập Single/Complete Linkage.
- Phân loại Core/Border/Noise trong DBSCAN.
- 1 chu kỳ E-step & M-step trong GMM.

② Bài tập Điền khuyết Code (Fill-in-the-Blank):

- Hoàn thiện code Scikit-Learn.
- Tự động chấm điểm (Assert test)