

CHUYÊN ĐỀ: PHÂN CỤM DỮ LIỆU TRONG MACHINE LEARNING

Lý Thuyết Toàn Diện, Ý Nghĩa Công Thức, Ví Dụ Tính Tay, Ứng Dụng Thực Tế & Cẩm Nang Lựa Chọn

TS. Vũ Đức Minh

Khoa Khoa học Dữ liệu và Trí tuệ Nhân tạo
Trường Công nghệ - Đại học Kinh tế Quốc dân (NEU)

2026


Mục tiêu Bài học (Learning Objectives)

- **Bản chất Phân cụm (Clustering):** Hiểu rõ triết lý Học không giám sát (Unsupervised Learning) và phân biệt **Hard Clustering** vs **Soft Clustering**.
- **Ý nghĩa Công thức & Độ đo Khoảng cách:** Hiểu trực giác toán học của WCSS, Linkage criteria, Mật độ ε -neighborhood, Định lý Bayes trong EM, và Hệ số Silhouette.
- **Làm chủ 5 trường phái thuật toán cốt lõi qua Ví dụ Tính tay:**
 - 1 **Centroid-based:** K-Means, K-Means++, Elbow Method, K-Medoids.
 - 2 **Connectivity-based:** Hierarchical Clustering, Dendrogram, 5 Linkage Criteria.
 - 3 **Density-based:** DBSCAN (Core/Border/Noise), OPTICS (Reachability Plot).
 - 4 **Distribution-based:** Gaussian Mixture Models (GMM), Thuật toán EM.
 - 5 **Fuzzy Clustering:** Fuzzy C-Means (FCM) với độ thuộc mờ u_{ik} .
- **Ứng dụng Thực tế Đột phá:** Nắm bắt các bài toán lớn trong E-commerce, Y sinh học, Ngân hàng chống gian lận, Định vị GPS và Xử lý tiếng nói.
- **Cẩm nang Lựa chọn Thuật toán:** Làm chủ ma trận kịch bản kinh doanh và kỹ thuật để chọn đúng mô hình phân cụm cho từng bài toán thực tế.

1. Bản chất của Phân cụm Dữ liệu (Clustering)

Khái niệm nền tảng (GeeksforGeeks):

- Là bài toán trung tâm của **Học không giám sát (Unsupervised Learning)**.
- Dữ liệu đầu vào chỉ có các biến đặc trưng $\mathcal{X} = \{x_1, \dots, x_N\}$, **không có nhãn mục tiêu** y .
- **Mục tiêu tối thượng:** Tự động gom các quan sát vào các nhóm (cụm) sao cho:
 - **Độ tương đồng nội cụm cao nhất** (High intra-cluster similarity).
 - **Độ phân tách ngoại cụm lớn nhất** (High inter-cluster dissimilarity).
- Cụm là tập hợp các điểm có hành vi, hình thái hoặc khoảng cách tương đồng.




Phân loại Hình thức: Hard Clustering vs Soft Clustering

1. Phân cụm cứng (Hard Clustering):

- Mỗi điểm x_i thuộc duy nhất về một cụm C_k với xác suất tuyệt đối 100%.
- Nhãn phân cụm nhị phân: $z_{ik} \in \{0, 1\}$ thỏa mãn $\sum_{k=1}^K z_{ik} = 1$.
- Đại diện tiêu biểu: K-Means, Hierarchical, DBSCAN.

2. Phân cụm mềm (Soft / Fuzzy Clustering):

- Mỗi điểm thuộc về tất cả các cụm với một **trọng số xác suất** hoặc mức độ thuộc (membership) $\gamma_{ik} \in [0, 1]$ thỏa mãn $\sum_{k=1}^K \gamma_{ik} = 1$.
- Đại diện tiêu biểu: GMM (EM), Fuzzy C-Means (FCM).



Các Độ đo Khoảng cách & Vai trò của Chuẩn hóa Dữ liệu

Các hàm khoảng cách thông dụng:

- **Euclidean Distance (L_2 norm):**

$$d(x, z) = \sqrt{\sum_{j=1}^d (x_j - z_j)^2}$$

Chuẩn mực cho biến định lượng liên tục cùng thang đo.

- **Manhattan Distance (L_1 norm / City Block):**

$$d(x, z) = \sum_{j=1}^d |x_j - z_j|$$

Bền vững hơn trước outliers, phù hợp không gian lưới.

- **Cosine Similarity (Góc vector):**

Distance Metrics in Hierarchical Clustering



Minimum Distance



Maximum Distance



Group Average



Ward's Method

Lưu ý sống còn: Phải thực hiện **Chuẩn hóa dữ liệu (StandardScaler)** trước khi tính khoảng cách, nếu không biến có giá trị lớn (ví dụ: Thu nhập 10^7) sẽ áp đảo hoàn toàn biến nhỏ (Tuổi 10^1)!

Bức tranh Toàn cảnh: 5 Trường phái Phân cụm Chính

Trường phái	Triết lý Gom cụm	Thuật toán	Tiêu biểu	Đặc trưng Hình học
Centroid-based	Đại diện cụm bằng một tâm điểm trung tâm	K-Means, Means++, K-Medoids	K	Hình cầu lồi (Spherical), ô Voronoi
Connectivity	Dựa trên khoảng cách lân cận giữa các mẫu	Agglomerative, Divisive, BIRCH		Cây phân cấp đa tầng (Dendrogram)
Density-based	Cụm là vùng mật độ cao cách biệt bởi vùng thưa	DBSCAN, HDBSCAN	OPTICS,	Hình dạng tùy ý, tự động lọc nhiễu
Distribution	Dữ liệu sinh ra từ tổ hợp các phân phối xác suất	Gaussian Mixture Model (GMM), EM		Hình Elip tự do, xác suất thành viên mềm
Fuzzy / Mờ	Điểm thuộc về cụm theo mức độ mờ ($u_{ik} \in [0, 1]$)	Fuzzy C-Means (FCM)		Cụm giao thoa, đường biên mờ

2. Centroid-based: Thuật toán K-Means Cổ điển

Quy trình 4 bước của Lloyd (1957):

- ➊ **Khởi tạo:** Chọn ngẫu nhiên K tâm cụm $\mu_1, \dots, \mu_K$.
- ➋ **Gán cụm (Assignment):** Gán mỗi điểm x_i vào cụm có tâm gần nhất:

$$c^{(i)} = \arg \min_k \|x_i - \mu_k\|_2^2$$


- ➌ **Cập nhật tâm (Update):** Tính lại tọa độ trọng tâm:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

- ➍ **Lặp lại** bước 2 và 3 cho đến khi tâm không đổi.

Hàm mục tiêu (WCSS / Inertia):

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2 \rightarrow \min$$



K-Means: Giải thích Ý nghĩa Toán học & Trực giác Công thức

1. Ý nghĩa của Hàm WCSS (Inertia):

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2$$

- Đo **tổng bình phương độ lệch** của các điểm so với tâm cụm tương ứng.
- Tương đương với việc tối thiểu hóa tổng phương sai nội cụm (Compactness).
- **Tại sao tâm là trung bình cộng?** Đạo hàm riêng theo μ_k :

$$\frac{\partial J}{\partial \mu_k} = -2 \sum_{x_i \in C_k} (x_i - \mu_k) = 0 \implies \mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

→ Mean chính là nghiệm cực tiểu giải tích duy nhất cho khoảng cách bình phương Euclidean!

2. Ý nghĩa Xác suất K-Means++:

$$P(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2}$$

- $D(x)$: Khoảng cách từ điểm x tới tâm gần nhất đã được chọn trước đó.
- **Trực giác:** $D(x)^2$ khuếch đại xác suất chọn các điểm **ở rất xa các tâm đã có**.
- **Tác dụng sống còn:** Đẩy các tâm khởi tạo tản đều ra toàn không gian, tránh hiện tượng 2 tâm rơi sát nhau trong cùng 1 cụm dày.
- **Cam kết toán học:** Giảm $O(e^K)$ rủi ro cực tiểu cục bộ xuống kỳ vọng đạt cận $O(\log K)$ so với lời giải tối ưu toàn cục.

K-Means: Ví dụ Tính tay Chi tiết Từng bước (1 Vòng lặp)

Bài toán mẫu: Cho 4 quan sát 2 chiều: $A(1, 1), B(2, 1), C(4, 3), D(5, 4)$. Cần phân thành $K = 2$ cụm.

Khởi tạo: Chọn tâm ban đầu $\mu_1^{(0)} = A(1, 1)$ và $\mu_2^{(0)} = D(5, 4)$.

Bước 1: Tính khoảng cách bình phương & Gán cụm

- Điểm $A(1, 1)$: $d^2(A, \mu_1) = 0$;
 $d^2(A, \mu_2) = (1-5)^2 + (1-4)^2 = 16+9 = 25 \Rightarrow \mathbf{A} \in \mathbf{C}_1$.
- Điểm $B(2, 1)$: $d^2(B, \mu_1) = (2-1)^2 + 0 = 1$;
 $d^2(B, \mu_2) = 9 + 9 = 18 \Rightarrow \mathbf{B} \in \mathbf{C}_1$.
- Điểm $C(4, 3)$: $d^2(C, \mu_1) = 9 + 4 = 13$;
 $d^2(C, \mu_2) = (4-5)^2 + (3-4)^2 = 2 \Rightarrow \mathbf{C} \in \mathbf{C}_2$.
- Điểm $D(5, 4)$: $d^2(D, \mu_1) = 16 + 9 = 25$;
 $d^2(D, \mu_2) = 0 \Rightarrow \mathbf{D} \in \mathbf{C}_2$.

$\Rightarrow$ Phân cụm vòng 1: $C_1 = \{A, B\}, C_2 = \{C, D\}$.

Bước 2: Cập nhật tọa độ tâm cụm mới $\mu^{(1)}$

$$\mu_1^{(1)} = \frac{A+B}{2} = \left(\frac{1+2}{2}, \frac{1+1}{2} \right) = \mathbf{(1.5, 1.0)}$$

$$\mu_2^{(1)} = \frac{C+D}{2} = \left(\frac{4+5}{2}, \frac{3+4}{2} \right) = \mathbf{(4.5, 3.5)}$$

Bước 3: Đánh giá suy giảm của hàm WCSS (J)

- $J^{(0)} = d^2(A, \mu_1^{(0)}) + d^2(B, \mu_1^{(0)}) + d^2(C, \mu_2^{(0)}) + d^2(D, \mu_2^{(0)}) = 0 + 1 + 2 + 0 = \mathbf{3.0}$.
- $J^{(1)} = 2 \times [(0.5)^2 + 0] + 2 \times [(0.5)^2 + (0.5)^2] = 0.5 + 1.0 = \mathbf{1.5}$.

$\Rightarrow$ WCSS giảm từ 3.0 $\rightarrow$ 1.5! Nếu lặp tiếp, gán cụm không đổi $\rightarrow$ Hội tụ!

Centroid-based: Ứng dụng Thực tế & Trường hợp Phù hợp

1. Ứng dụng Thực tế Đột phá:

- **Phân khúc Khách hàng RFM (E-commerce):** Shopee/Tiki nhóm khách hàng theo 3 biến: Recency (ngày mua gần nhất), Frequency (tần suất), Monetary (chi tiêu). Cụm $K = 4$: VIP, Khách hàng trung thành, Khách tiềm năng, Khách nguy cơ rời bỏ.
- **Nén Ảnh (Color Quantization):** Ảnh RGB 24-bit có 16.7 triệu màu. K-Means gom các pixel thành $K = 16$ hoặc 64 màu tâm cụm, lưu trữ dạng Palette, giảm 75 – 85% dung lượng ảnh mà mắt thường khó nhận biết.
- **Tối ưu Vị trí Kho bãi / Trạm sạc EV:** Tìm tọa độ tâm cụm μ_k giảm thiểu tổng quãng đường vận chuyển tới khách hàng.

2. Cẩm nang Lựa chọn (Khi nào nên dùng?):

● NÊN DÙNG KHI:

- Dữ liệu quy mô lớn ($N > 10^5 \rightarrow 10^7$).
- Cụm có hình thái hình cầu lồi (Spherical), kích thước và mật độ các cụm tương đương nhau.
- Cần tốc độ huấn luyện nhanh, dễ triển khai lên Production.

● KHÔNG NÊN DÙNG KHI:

- Cụm có hình dạng phi cầu (hình lưới liềm, vành khuyên, xoắn ốc).
- Dữ liệu có nhiều ngoại lai (K-Means bị lệch tâm, nên đổi sang **K-Medoids / PAM**).
- Các cụm có mật độ chênh lệch quá lớn.

3. Connectivity-based: Phân cụm Phân cấp (Hierarchical)

Hai hướng tiếp cận đối ngẫu:


① Agglomerative (Tích tụ / Bottom-Up):

- Bắt đầu: N cụm đơn lẻ (N lá).
- Mỗi bước: Gộp 2 cụm gần nhau nhất.
- Kết thúc: 1 siêu cụm duy nhất (Gốc).

② Divisive (Phân tách / Top-Down):

- Bắt đầu: 1 cụm tổng thể chứa toàn bộ dữ liệu.
- Phân rã đệ quy thành các cụm nhỏ hơn.

Ưu thế nổi bật: Không cần chọn trước số lượng cụm K khi dựng cây! Cung cấp bức tranh cấu trúc ở mọi mức độ chi tiết.



Hierarchical: Ý nghĩa Toán học & Trực giác 5 Tiêu chuẩn Linkage

1. Single Linkage (Khoảng cách Tối thiểu):

$$D(A, B) = \min_{x \in A, y \in B} d(x, y)$$

- **Ý nghĩa:** Gom 2 cụm dựa trên khoảng cách giữa 2 điểm gần nhau nhất (Nearest-neighbor chaining).
- **Điểm yếu chí mạng:** Dễ bị **Hiện tượng nối chuỗi (Chaining Effect)** - một cây cầu gồm vài điểm nhiều có thể nối dính 2 cụm khổng lồ hoàn toàn tách biệt.

2. Complete Linkage (Khoảng cách Tối đa):

$$D(A, B) = \max_{x \in A, y \in B} d(x, y)$$

- **Ý nghĩa:** Khoảng cách giữa 2 điểm xa nhất. Ép các cụm sáp nhập phải có đường kính bao nhỏ gọn, tạo cụm tròn đặc. Rất nhạy cảm với ngoại

3. Average Linkage (Trung bình):

$$D(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} d(x, y)$$

- Cân bằng giữa Single và Complete, ít nhạy cảm với nhiễu.

4. Phương pháp Ward (Ward's Minimum Variance):

$$\Delta \text{WCSS} = \frac{|A||B|}{|A| + |B|} \|\mu_A - \mu_B\|_2^2$$

- **Ý nghĩa:** Chọn sáp nhập 2 cụm làm **tổng phương sai nội cụm tăng ít nhất**.
- **Khuyến nghị thực tế:** Đây là tiêu chuẩn liên kết **hiệu quả nhất, phổ biến nhất** trên dữ liệu thực tế!

Hierarchical: Ví dụ Tính tay Cụm Phân cấp & Dựng Dendrogram

Bài toán mẫu: Cho 3 điểm 1 chiều: $A = 1.0, B = 2.0, C = 6.0$. Cần xây dựng cây phân cụm phân cấp Agglomerative.
Ma trận khoảng cách ban đầu D_0 : $d(A, B) = |1 - 2| = 1.0$, $d(B, C) = |2 - 6| = 4.0$, $d(A, C) = |1 - 6| = 5.0$.

Bước 1: Sáp nhập Cặp gần nhau nhất

- Cặp có khoảng cách nhỏ nhất là (A, B) với $d(A, B) = 1.0$.
- Sáp nhập thành cụm mới $C_1 = \{A, B\}$ ở độ cao $h = 1.0$.

Bước 2: Cập nhật khoảng cách từ $\{A, B\}$ tới C

- **Single Linkage:**

$$D_{\text{single}}(\{A, B\}, C) = \min(d(A, C), d(B, C)) = \min(5, 4) = 4.0$$


- **Complete Linkage:**

$$D_{\text{complete}}(\{A, B\}, C) = \max(d(A, C), d(B, C)) = \max(5, 4) = 5.0$$

- **Ward's Method** ($\mu_{\{A, B\}} = 1.5, \mu_C = 6$):

$$\Delta \text{WCSS} = \frac{2 \times 1}{2 + 1} (1.5 - 6)^2 = \frac{2}{3} \times 20.25 = 13.5$$

Bước 3: Phân tích Cắt Cây Dendrogram



Quy tắc cắt cụm tối ưu:

- Nếu muốn $K = 2$ cụm: Cắt cây ở độ cao $1.5 < h < 4.0$. Kết quả thu được cụm $\{A, B\}$ và $\{C\}$.
- Nhánh dọc từ $1.0 \rightarrow 4.0$ (chiều dài $\Delta h = 3.0$) là nhánh dài nhất không bị ngắt quãng $\rightarrow$ Khẳng định $K = 2$ là cấu trúc tự nhiên mạnh nhất!

Connectivity-based: Ứng dụng Thực tế & Trường hợp Phù hợp

1. Ứng dụng Thực tế Đột phá:

- **Sinh học & Phân tích Gen (Bioinformatics):** Biểu đồ nhiệt Heatmap kết hợp Dendrogram (Clustered Heatmap) nhóm hàng nghìn gen có mô hình biểu hiện đồng thời, giúp tìm ra các nhóm gen gây ung thư hoặc đáp ứng thuốc.
- **Xây dựng Cây Phân loại Ngành hàng (Taxonomy):** Phân cấp đa tầng cho hàng triệu SKU bán lẻ: Ngành hàng → Danh mục chính → Tiểu mục → Sản phẩm.
- **Ngôn ngữ học & Phát sinh Loài:** Xây dựng cây phả hệ tiến hóa sinh vật (Phylogenetic Tree) hoặc phả hệ nguồn gốc các ngữ hệ thế giới.

2. Cảnh nang Lựa chọn (Khi nào nên dùng?):

● NÊN DÙNG KHI:

- Nghiệp vụ bắt buộc phải xem xét mối quan hệ phân cấp đa tầng (phòng ban, danh mục).
- Kích thước dữ liệu nhỏ đến vừa ($N < 5,000$).
- Chưa biết số cụm K và muốn linh hoạt thay đổi mức độ gom nhóm bằng cách trượt đường cắt trên Dendrogram.

● KHÔNG NÊN DÙNG KHI:

- Dữ liệu lớn ($N > 20,000$) do bộ nhớ $O(N^2)$ làm tràn RAM và thời gian $O(N^3)$.
- Các quyết định sáp nhập sai lầm ở bước đầu không thể sửa đổi (No backtracking).

4. Density-based: Thuật toán DBSCAN


Hai siêu tham số cốt lõi:

- ϵ (Epsilon): Bán kính lân cận vùng khảo sát.
- MinPts: Số lượng mẫu tối thiểu trong bán kính ϵ .

Phân loại 3 nhóm điểm:

- **Core Point:** $|N_\epsilon(p)| \geq \text{MinPts}$.
- **Border Point:** $|N_\epsilon(p)| < \text{MinPts}$ nhưng nằm trong bán kính ϵ của một Core Point.
- **Noise Point:** Không thuộc 2 nhóm trên (gán nhãn **-1**).

Cơ chế lan truyền cụm: Liên thông mật độ thông qua các chuỗi điểm tiếp cận trực tiếp.



DBSCAN & OPTICS: Ý nghĩa Toán học & Trực giác Mật độ

1. Ý nghĩa Mật độ Ngưỡng DBSCAN:

- Vùng lân cận: $N_\varepsilon(p) = \{q \in \mathcal{X} \mid d(p, q) \leq \varepsilon\}$.
- **Mật độ tối thiểu được định nghĩa bởi:**

$$\rho_{\min} = \frac{\text{MinPts}}{V_\varepsilon}, \quad V_\varepsilon \propto \varepsilon^d$$

- Một vùng không gian được xem là "**Cụm**" nếu mật độ thực tế lớn hơn $\rho_{\min}$.
- **Cơ chế miễn nhiễm Outliers:** Những điểm nằm rải rác ở vùng có mật độ $< \rho_{\min}$ lập tức bị cô lập thành Noise (Nhãn -1), không làm lệch hình dạng cụm chính.

2. Ý nghĩa Reachability Distance (OPTICS):

$$\text{rd}(p, o) = \max(\text{core-dist}(o), d(o, p))$$

- DBSCAN thất bại khi các cụm có mật độ khác nhau (chỗ quá đặc, chỗ hơi loãng).
- OPTICS giải quyết bằng cách **làm mịn khoảng cách**: Điểm p chỉ có thể được tiếp cận từ o với khoảng cách tối thiểu bằng Core Distance của o .
- **Reachability Plot**: Thung lũng biểu thị cụm mật độ cao, đỉnh núi nhô cao biểu thị ranh giới chia cắt cụm hoặc điểm ngoại lai.

DBSCAN: Ví dụ Tính tay Phân loại Điểm (Core, Border, Noise)

Bài toán mẫu: Cho 5 điểm trên trục số 1D: $x_1 = 1.0, x_2 = 1.8, x_3 = 2.5, x_4 = 5.0, x_5 = 9.0$.

Cấu hình siêu tham số: Bán kính $\epsilon = 1.0$, Số điểm tối thiểu MinPts = 2.

Bước 1: Quét láng giềng ϵ -neighborhood cho từng điểm

- Điểm $x_1(1.0)$: $N_{1.0}(x_1) = \{x_1, x_2\}$ vì $|1.0 - 1.8| = 0.8 \leq 1.0$. Số láng giềng = **2** $\geq$ MinPts $\Rightarrow$ **Core Point**.
- Điểm $x_2(1.8)$: $N_{1.0}(x_2) = \{x_1, x_2, x_3\}$ vì cách x_1 0.8 và x_3 0.7. Số láng giềng = **3** $\geq$ MinPts $\Rightarrow$ **Core Point**.
- Điểm $x_3(2.5)$: $N_{1.0}(x_3) = \{x_2, x_3\}$ vì $|2.5 - 1.8| = 0.7 \leq 1.0$. Số láng giềng = **2** $\geq$ MinPts $\Rightarrow$ **Core Point**.
- Điểm $x_4(5.0)$: $N_{1.0}(x_4) = \{x_4\}$ (chỉ có chính nó). Số láng giềng = **1** $<$ MinPts và cách Core gần nhất x_3 là $2.5 > \epsilon \Rightarrow$ **Noise Point**.
- Điểm $x_5(9.0)$: $N_{1.0}(x_5) = \{x_5\}$. Số láng giềng = **1** $<$ MinPts $\Rightarrow$ **Noise Point**.

Bước 2: Lan truyền tạo cụm & Gán nhãn

- Xuất phát từ Core x_1 : kết nạp x_2 .
- Từ Core x_2 : kết nạp tiếp x_3 .
- Cả 3 điểm x_1, x_2, x_3 liên thông mật độ với nhau!

Kết quả Phân cụm Hoàn chỉnh:

Điểm	Vai trò	Nhãn Phân cụm
x_1, x_2, x_3	Core Point	Cụm 1 Ngoại lai (Nhãn -1) Ngoại lai (Nhãn -1)
x_4	Noise	
x_5	Noise	

Nhận xét: DBSCAN tự động tìm ra 1 cụm đặc và đào thải chuẩn xác 2 điểm dị thường x_4, x_5 !

Density-based: Ứng dụng Thực tế & Trường hợp Phù hợp

1. Ứng dụng Thực tế Đột phá:

- **Phát hiện Gian lận Thẻ tín dụng & An ninh mạng:** Hành vi tiêu dùng bình thường tạo thành các cụm dày đặc. Các giao dịch rửa tiền hoặc tấn công DDoS rơi vào vùng mật độ cực thấp → DBSCAN gán nhãn -1 (Noise) phát cảnh báo tức thì.
- **Gom cụm GPS Giao thông (Grab, Be, Uber):** Gom hàng triệu tọa độ GPS đón/trả khách để phát hiện điểm nóng tắc đường (Traffic Hotspots), đề xuất trạm đón xe mà không bị nhiễu do lỗi sóng GPS làm méo mó.
- **Thiên văn học:** Phát hiện các chòm sao, dải thiên hà xoắn ốc uốn lượn giữa không gian vũ trụ bao la.

2. Cẩm nang Lựa chọn (Khi nào nên dùng?):

● **NÊN DÙNG KHI:**

- Cụm có hình dạng hình học phức tạp, uốn lượn, phi tuyến tính (non-spherical).
- Dữ liệu có tỷ lệ ngoại lai và nhiễu cao cần loại bỏ tự động.
- Hoàn toàn không biết trước số lượng cụm K .

● **KHÔNG NÊN DÙNG KHI:**

- Dữ liệu có mật độ các cụm biến thiên mạnh (chuyển sang dùng **OPTICS** hoặc **HDBSCAN**).
- Không gian số chiều rất lớn ($d > 20$) vì thể tích khối cầu nở ra quá nhanh làm khoảng cách bị bão hòa (Curse of Dimensionality).

5. Distribution-based: Gaussian Mixture Models (GMM)


Mô hình xác suất tạo sinh (Generative Model):

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

- π_k : Trọng số thành phần ($\sum \pi_k = 1$).
- μ_k : Vector kỳ vọng (tâm cụm).
- Σ_k : Ma trận hiệp phương sai (hình dạng elip).

Phân cụm mềm (Soft Assignment):

$$\gamma_{nk} = P(z_{nk} = 1 \mid x_n) = \frac{\pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n \mid \mu_j, \Sigma_j)}$$



Thuật toán EM: Ý nghĩa Toán học & Trực giác Bước E-step / M-step

1. Trực giác Bước E-step (Expectation):

$$\gamma_{nk} = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \mu_j, \Sigma_j)}$$

- Thực chất là áp dụng **Định lý Bayes**: Tính xác suất hậu nghiệm (Posterior) rằng điểm $\mathbf{x}_n$ được sinh ra từ cụm Gaussian thứ k .
- Không gán nhãn cứng kiểu nhị phân 0/1, mà phân bổ **"trách nhiệm mềm"** (ví dụ: 80% thuộc Cụm 1, 20% thuộc Cụm 2).

2. Trực giác Bước M-step (Maximization):

$$\mu_k = \frac{\sum_{n=1}^N \gamma_{nk} \mathbf{x}_n}{\sum_{n=1}^N \gamma_{nk}}, \quad N_k = \sum_{n=1}^N \gamma_{nk}$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

- Mỗi điểm dữ liệu đều đóng góp vào việc điều chỉnh tọa độ tâm μ_k và ma trận xoay Σ_k theo đúng tỷ lệ trách nhiệm γ_{nk} .
- **Bảo đảm toán học**: Giá trị Log-Likelihood $\ln p(\mathcal{X} | \theta)$ luôn tăng đơn điệu sau mỗi vòng lặp!

GMM: Ví dụ Tính tay Bước E-step (Tính Ma trận Trách nhiệm γ)

Bài toán mẫu: Cho 2 cụm Gaussian 1D: Cụm 1 $\sim \mathcal{N}(\mu_1 = 2.0, \sigma_1^2 = 1.0)$, Cụm 2 $\sim \mathcal{N}(\mu_2 = 6.0, \sigma_2^2 = 1.0)$. Trọng số tiên nghiệm cân bằng: $\pi_1 = \pi_2 = 0.5$. Cần tính trách nhiệm mềm γ_1, γ_2 cho quan sát $x = 3.0$.

Bước 1: Tính hàm mật độ xác suất Gaussian $\mathcal{N}(x | \mu, \sigma)$

Hàm mật độ chuẩn 1D: $\mathcal{N}(x | \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$. Với $\sigma = 1.0 \Rightarrow \frac{1}{\sqrt{2\pi}} \approx 0.3989$.

- Đối với Cụm 1 ($\mu_1 = 2.0$):

$$\mathcal{N}(3.0 | 2.0, 1.0) = 0.3989 \times e^{-\frac{(3-2)^2}{2}} = 0.3989 \times e^{-0.5} \approx \mathbf{0.2420}$$

- Đối với Cụm 2 ($\mu_2 = 6.0$):

$$\mathcal{N}(3.0 | 6.0, 1.0) = 0.3989 \times e^{-\frac{(3-6)^2}{2}} = 0.3989 \times e^{-4.5} \approx \mathbf{0.0044}$$

Bước 2: Tính xác suất hậu nghiệm (E-step) Mẫu số tổng hợp:

$$p(x = 3) = \pi_1 \mathcal{N}_1 + \pi_2 \mathcal{N}_2 = 0.5(0.2420) + 0.5(0.0044) = \mathbf{0.1232}$$

Áp dụng định lý Bayes tính trách nhiệm γ :

$$\gamma_1 = \frac{0.5 \times 0.2420}{0.1232} = \frac{0.1210}{0.1232} \approx \mathbf{0.982 \text{ (98.2\%)}}$$

$$\gamma_2 = \frac{0.5 \times 0.0044}{0.1232} = \frac{0.0022}{0.1232} \approx \mathbf{0.018 \text{ (1.8\%)}}$$

Ý nghĩa kết quả: Điểm $x = 3$ thuộc Cụm 1 với độ tin cậy 98.2%, và chỉ có 1.8% khả năng thuộc Cụm 2.

Distribution-based: Ứng dụng Thực tế & Trường hợp Phù hợp

1. Ứng dụng Thực tế Đột phá:

- **Xử lý Tiếng nói & Tách Người nói (Speaker Diarization):** Tự động xác định "Ai nói khi nào" trong cuộc họp. Các đặc trưng âm phổ MFCC của từng giọng nói được mô hình hóa thành các phân phối Gaussian đa chiều.
- **Phân đoạn Ảnh Y tế (Brain MRI Segmentation):** Mô não thực tế có vùng ranh giới chuyển tiếp (Partial Volume Effect) giữa chất xám, chất trắng và dịch não tủy. GMM cung cấp xác suất mềm phản ánh trung thực độ pha trộn mô học.
- **Mô hình hóa Rủi ro Tài chính (Regime Switching):** Mô hình hóa thị trường chứng khoán gồm nhiều trạng thái (Thị trường Bò, Gấu, Đi ngang).

2. Cảnh nang Lựa chọn (Khi nào nên dùng?):

● **NÊN DÙNG KHI:**

- Cụm có dạng hình bầu dục (Elip) tự do mọi hướng với kích thước và độ lệch chuẩn khác nhau.
- Nghiệp vụ yêu cầu gán mềm (Soft clustering), cần đo lường mức độ không chắc chắn (Uncertainty).
- Dữ liệu có sự giao thoa, chồng lấn ranh giới tự nhiên.

● **KHÔNG NÊN DÙNG KHI:**

- Cụm có hình phi elip (chữ U, xoắn ốc).
- Số chiều d quá lớn khiến ma trận hiệp phương sai Σ ($d \times d$) có quá nhiều tham số, dễ bị suy biến (Singular covariance matrix).

Trường phái Thứ 5: Phân cụm Mờ (Fuzzy C-Means - FCM)

Bản chất Phân cụm Mờ (Bezdek, 1981):

- Mở rộng mềm từ K-Means, mỗi điểm thuộc về tất cả các cụm với mức độ mờ $u_{ik} \in [0, 1]$ thỏa mãn $\sum_{k=1}^K u_{ik} = 1$.

Hàm mục tiêu mờ ($m > 1$ là tham số mờ hóa):

$$J_m = \sum_{i=1}^N \sum_{k=1}^K u_{ik}^m \|x_i - \mu_k\|^2 \rightarrow \min$$

Công thức tính độ thuộc u_{ik} & Tâm μ_k :

$$u_{ik} = \frac{1}{\sum_{j=1}^K \left(\frac{\|x_i - \mu_k\|}{\|x_i - \mu_j\|} \right)^{\frac{2}{m-1}}}, \quad \mu_k = \frac{\sum_{i=1}^N u_{ik}^m x_i}{\sum_{i=1}^N u_{ik}^m}$$

Ví dụ Tính tay FCM với $m = 2$:

- Cho điểm $x = 2.0$ giữa 2 tâm $\mu_1 = 1.0, \mu_2 = 5.0$.
- Khoảng cách: $d_1 = |2 - 1| = 1.0$,
 $d_2 = |2 - 5| = 3.0$.
- Độ thuộc Cụm 1:

$$u_1 = \frac{1}{\left(\frac{1}{1}\right)^2 + \left(\frac{1}{3}\right)^2} = \frac{1}{1 + \frac{1}{9}} = \mathbf{0.9 \text{ (90\%)}}$$

- Độ thuộc Cụm 2: $u_2 = 1 - 0.9 = \mathbf{0.1 \text{ (10\%)}}$.

Ứng dụng & Trường hợp phù hợp:

Chăm điểm khách hàng đa kênh (Omnichannel), phân tích ranh giới tổn thương mô tế bào bệnh học mà không cần giả định phân phối chuẩn như GMM.

6. Đánh giá Chất lượng Phân cụm: Ý nghĩa Công thức

Giải phẫu Hệ số Silhouette ($s \in [-1, 1]$):

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- **$a(i)$:** Khoảng cách trung bình từ i đến các điểm **cùng cụm** (Độ gắn kết nội cụm - Cohesion). **Càng nhỏ càng tốt!**
- **$b(i)$:** Khoảng cách trung bình từ i đến các điểm thuộc **cụm lân cận gần nhất** (Độ tách biệt ngoại cụm - Separation). **Càng lớn càng tốt!**
- **Ý nghĩa giá trị $s(i)$:**
 - $s \approx +1$: $b(i) \gg a(i) \Rightarrow$ Phân cụm rất hoàn hảo!
 - $s \approx 0$: $a(i) \approx b(i) \Rightarrow$ Điểm nằm ngay đường ranh giới.
 - $s < 0$: $a(i) > b(i) \Rightarrow$ Điểm bị gán nhầm cụm!


Các chỉ số khác:

- **Davies-Bouldin Index (DBI):** Tỷ số giữa độ tản mát nội cụm và khoảng cách tâm. **Càng nhỏ càng tốt.**
 - **Calinski-Harabasz (CH):** Tỷ số phương sai liên cụm / nội cụm. **Càng lớn càng tốt.**
- Khi có nhãn đối chuẩn (External):**
- **Adjusted Rand Index (ARI $\in [-1, 1]$):** Tỷ lệ cặp điểm xếp đúng, khử yếu tố ngẫu nhiên.
 - **NMI ($[0, 1]$):** Tương hỗ thông tin chuẩn hóa.

Bảng So sánh Tổng hợp 5 Trường phái Thuật toán

Tiêu chí	K-Means	Hierarchical	DBSCAN	OPTICS	GMM / FCM
Loại phân cụm	Cứng (Hard)	Cứng (Hard)	Cứng (Hard)	Cứng (Hard)	Mềm (Soft)
Cần chọn trước K?	Bắt buộc	Không	Không	Không	Bắt buộc
Hình thái cụm	Hình cầu lõi	Hình cầu / Linh hoạt	Bất kỳ (Phi tuyến)	Bất kỳ (Phi tuyến)	Hình Elip tự do
Cụm đa mật độ	Kém	Trung bình	Kém	Rất tốt	Tốt
Xử lý ngoại lai	Kém (bị kéo tâm)	Kém	Tự động lọc	Tự động lọc	Trung bình
Độ phức tạp Time	$O(N \cdot K \cdot I)$	$O(N^2 \log N)$	$O(N \log N) \rightarrow O(N^2)$	$O(N \log N) \rightarrow O(N^2)$	$O(N \cdot K \cdot I \cdot d^3)$
Độ phức tạp Space	$O(N \cdot d)$	$O(N^2)$	$O(N)$	$O(N)$	$O(N \cdot d + K \cdot d^2)$
Đầu ra trực quan	Tâm cụm, Voronoi	Dendrogram	Nhãn cụm phẳng	Reachability Plot	Elip tin cậy

Cây Quyết định Lựa chọn Thuật toán trong Thực tế



Cẩm nang Kịch bản Thực tế: Khi Nào Dùng Thuật Toán Nào?

Kịch bản Ứng dụng & Dữ liệu	Thuật toán Đề xuất	Lý do Kỹ thuật & Điểm Lưu ý
Phân khúc khách hàng TMĐT ($N > 10^6$, biến RFM, cụm cầu)	K-Means++ / Mini-Batch	Thời gian chạy siêu nhanh $O(N)$, tầm cụm trực quan giúp ban giám đốc ra quyết định ngay.
Phát hiện rửa tiền, gian lận (Nhiều giao dịch bất thường)	DBSCAN	Tự động đào thải ngoại lai thành Noise (nhãn -1) mà không làm lệch kết quả phân tích.
Điểm nóng giao thông GPS (Mật độ biến thiên, hình cung đường)	OPTICS / HDBSCAN	Bất trộn các cung đường uốn lượn và thích ứng các vùng mật độ giao thông chênh lệch.
Cây danh mục ngành hàng, Phân tích biểu hiện gen ($N < 5000$)	Hierarchical (Ward Linkage)	Biểu đồ Dendrogram trực quan hóa cấu trúc phả hệ đa cấp; không cần phỏng đoán số cụm K .
Phân đoạn mô não MRI, Tách giọng nói cuộc họp	GMM (EM Algorithm)	Phân cụm mềm (Soft assignment) định lượng độ không chắc chắn tại các ranh giới mô giao thoa.
Chấm điểm tín dụng vùng biên, Khách hàng đa kênh	Fuzzy C-Means (FCM)	Độ thuộc mờ $u_{ik} \in [0, 1]$ xử lý xuất sắc các trường hợp khách hàng "nửa nọ nửa kia".

Thách thức & Giới hạn của Phân cụm Dữ liệu (GeeksforGeeks)

1. Xác định số lượng cụm K tối ưu:

- Vì không có nhãn đối chuẩn, việc chọn K mang tính chủ quan.
- Đòi hỏi kết hợp Elbow, Silhouette và kiến thức nghiệp vụ miền (Domain Knowledge).

2. Độ nhạy cảm với Khởi tạo & Outliers:

- K-Means dễ rơi vào cực tiểu cục bộ nếu không dùng K-Means++.
- Ngoại lai có thể làm sai lệch hoàn toàn vị trí tâm cụm.

3. Lời nguyền Số chiều (Curse of Dimensionality):

- Khi số chiều d quá lớn, khoảng cách giữa các cặp điểm đều tiến về một giá trị tương đương (Distance Concentration).
- *Giải pháp:* Cần giảm chiều bằng PCA/t-SNE trước khi gom cụm.

4. Chi phí Tính toán trên Big Data:

- Hierarchical ($O(N^2)$ bộ nhớ) bất khả thi khi $N > 20,000$.
- Cần chuyển sang Mini-Batch K-Means hoặc BIRCH.

Tổng kết & Lộ trình Thực hành Lab

Tóm tắt bài học:

- Phân cụm là công cụ khám phá cấu trúc tự nhiên mạnh mẽ nhất của Khoa học Dữ liệu.
- Không có một thuật toán duy nhất tối ưu cho mọi bài toán (*No Free Lunch Theorem*).
- Lựa chọn thuật toán phụ thuộc chặt chẽ vào:
 - Kích thước dữ liệu N (Scale).
 - Hình thái hình học của cụm (Cầu vs Phi tuyến).
 - Tỷ lệ nhiễu và ngoại lai.
 - Yêu cầu bài toán kinh doanh (cứng hay mềm).

Nội dung Thực hành trong Notebook:

1 Bài tập tính tay (Hand Calculations):

- 1 vòng lặp K-Means trên tập số liệu mẫu.
- Sáp nhập Single/Complete Linkage.
- Phân loại Core/Border/Noise trong DBSCAN.
- 1 chu kỳ E-step & M-step trong GMM.

2 Bài tập Điền khuyết Code (Fill-in-the-Blank):

- Hoàn thiện code Scikit-Learn.
- Tự động chấm điểm (Assert test).