

CHUYÊN ĐỀ: PHÂN CỤM DỮ LIỆU TRONG MACHINE LEARNING

Từ Các Thuật Toán Cốt Lõi (K-Means, Hierarchical, DBSCAN, GMM, FCM) Đến Ứng Dụng Thực Tiễn

TS. Vũ Đức Minh

Khoa Khoa học Dữ liệu và Trí tuệ Nhân tạo
Trường Công nghệ - Đại học Kinh tế Quốc dân (NEU)

2026


Mục tiêu Bài học (Learning Objectives)

- **Bản chất Phân cụm (Clustering):** Hiểu rõ triết lý Học không giám sát (Unsupervised Learning) và phân biệt rạch ròi **Hard Clustering** vs **Soft Clustering**.
- **Độ đo Khoảng cách & Độ tương đồng:** Hiểu vai trò quyết định của Euclidean, Manhattan, Minkowski, Cosine và Hamming Distance.
- **Làm chủ 5 trường phái thuật toán cốt lõi:**
 - ① **Centroid-based:** K-Means, K-Means++, Elbow Method, K-Medoids.
 - ② **Connectivity-based:** Hierarchical Clustering, Agglomerative, Dendrogram, Linkage Criteria.
 - ③ **Density-based:** DBSCAN (Core/Border/Noise, K-distance graph), OPTICS (Reachability Plot).
 - ④ **Distribution-based:** Gaussian Mixture Models (GMM), Thuật toán Expectation-Maximization (EM).
 - ⑤ **Fuzzy Clustering:** Fuzzy C-Means (FCM) với độ thuộc mờ u_{ik} .
- **Đánh giá Chất lượng Mô hình:** Áp dụng các chỉ số nội tại (Silhouette, DBI, CH) và ngoại tại (ARI, NMI).
- **Ứng dụng & Lựa chọn Thuật toán:** Làm chủ 6 bài toán thực tiễn và cây quyết định lựa chọn mô hình.

1. Bản chất của Phân cụm Dữ liệu (Clustering)

Khái niệm nền tảng (GeeksforGeeks):

- Là bài toán trung tâm của **Học không giám sát (Unsupervised Learning)**.
- Dữ liệu đầu vào chỉ có các biến đặc trưng $\mathcal{X} = \{x_1, \dots, x_N\}$, **không có nhãn mục tiêu** y .
- **Mục tiêu tối thượng:** Tự động gom các quan sát vào các nhóm (cụm) sao cho:
 - **Độ tương đồng nội cụm cao nhất** (High intra-cluster similarity).
 - **Độ phân tách ngoại cụm lớn nhất** (High inter-cluster dissimilarity).
- Cụm là tập hợp các điểm có hành vi, hình thái hoặc khoảng cách tương đồng.




Phân loại Hình thức: Hard Clustering vs Soft Clustering

1. Phân cụm cứng (Hard Clustering):

- Mỗi điểm x_i thuộc duy nhất về một cụm C_k với xác suất tuyệt đối 100%.
- Nhãn phân cụm nhị phân: $z_{ik} \in \{0, 1\}$ thỏa mãn $\sum_{k=1}^K z_{ik} = 1$.
- Đại diện tiêu biểu: K-Means, Hierarchical, DBSCAN.

2. Phân cụm mềm (Soft / Fuzzy Clustering):

- Mỗi điểm thuộc về tất cả các cụm với một **trọng số xác suất** hoặc mức độ thuộc (membership) $\gamma_{ik} \in [0, 1]$ thỏa mãn $\sum_{k=1}^K \gamma_{ik} = 1$.
- Đại diện tiêu biểu: GMM (EM), Fuzzy C-Means (FCM).



Các Độ đo Khoảng cách & Độ tương đồng (Distance Metrics)

Các hàm khoảng cách thông dụng:

- **Euclidean Distance (L_2 norm):**

$$d(x, z) = \sqrt{\sum_{j=1}^d (x_j - z_j)^2}$$

Chuẩn mực cho biến định lượng liên tục cùng thang đo.

- **Manhattan Distance (L_1 norm / City Block):**

$$d(x, z) = \sum_{j=1}^d |x_j - z_j|$$

Bền vững hơn trước outliers, phù hợp không gian lưới.

- **Cosine Similarity (Góc vector):**

Distance Metrics in Hierarchical Clustering



Minimum Distance



Maximum Distance



Group Average



Ward's Method

Lưu ý sống còn: Phải thực hiện **Chuẩn hóa dữ liệu (StandardScaler)** trước khi tính khoảng cách, nếu không biến có giá trị lớn sẽ áp đảo mô hình!

Bức tranh Toàn cảnh: 5 Trường phái Phân cụm Chính

Trường phái	Triết lý Gom cụm	Thuật toán	Tiêu biểu	Đặc trưng Hình học
Centroid-based	Đại diện cụm bằng một tâm điểm trung tâm	K-Means, Means++, K-Medoids	K	Hình cầu lồi (Spherical), ô Voronoi
Connectivity	Dựa trên khoảng cách lân cận giữa các mẫu	Agglomerative, Divisive, BIRCH		Cây phân cấp đa tầng (Dendrogram)
Density-based	Cụm là vùng mật độ cao cách biệt bởi vùng thưa	DBSCAN, HDBSCAN	OPTICS,	Hình dạng tùy ý, tự động lọc nhiễu
Distribution	Dữ liệu sinh ra từ tổ hợp các phân phối xác suất	Gaussian Mixture Model (GMM), EM		Hình Elip tự do, xác suất thành viên mềm
Fuzzy / Mờ	Điểm thuộc về cụm theo mức độ mờ ($u_{ik} \in [0, 1]$)	Fuzzy C-Means (FCM)		Cụm giao thoa, đường biên mờ

2. Centroid-based: Thuật toán K-Means Cổ điển

Quy trình 4 bước của Lloyd (1957):

- ➊ **Khởi tạo:** Chọn ngẫu nhiên K tâm cụm $\mu_1, \dots, \mu_K$.
- ➋ **Gán cụm (Assignment):** Gán mỗi điểm x_i vào cụm có tâm gần nhất:

$$c^{(i)} = \arg \min_k \|x_i - \mu_k\|_2^2$$


- ➌ **Cập nhật tâm (Update):** Tính lại tọa độ trọng tâm:

$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

- ➍ **Lặp lại** bước 2 và 3 cho đến khi tâm không đổi.

Hàm mục tiêu (WCSS / Inertia):

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2 \rightarrow \min$$



Centroid-based: K-Means++ và Phương pháp Khuỷu tay


K-Means++ (Arthur & Vassilvitskii, 2007):

- Khởi tạo tâm ngẫu nhiên để rơi vào **cực tiểu cục bộ kém**.
- K-Means++ chọn tâm tiếp theo với xác suất tỷ lệ thuận với bình phương khoảng cách tới tâm gần nhất:

$$P(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2}$$

- **Đảm bảo lý thuyết:** Kỳ vọng nghiệm đạt xấp xỉ $O(\log K)$ so với tối ưu toàn cục.

Phương pháp Khuỷu tay (Elbow Method):



- Vẽ đồ thị Inertia (WCSS) theo số cụm K .
- Chọn K tại **điểm gãy (Elbow)** nơi tốc độ giảm WCSS bắt đầu chững lại rõ rệt.

Centroid-based: Biến thể Bền vững K-Medoids (PAM)

Vấn đề của K-Means với Outliers:


- Điểm trung bình cộng (Mean) cực kỳ nhạy cảm với ngoại lai, làm lệch tâm cụm nghiêm trọng.

Giải pháp K-Medoids (Kaufman & Rousseeuw, 1987):

- Tâm cụm bắt buộc phải là **một điểm dữ liệu thực tế** trong tập dữ liệu (Medoid).
- Tối ưu hàm mất mát khoảng cách trị tuyệt đối (L_1 norm):

$$J_{\text{medoid}} = \sum_{k=1}^K \sum_{x \in C_k} \|x - m_k\|_1 \rightarrow \min$$

- Ưu điểm:** Cực kỳ kiên cường trước nhiễu



3. Connectivity-based: Phân cụm Phân cấp (Hierarchical)

Hai hướng tiếp cận đối ngẫu:


① **Agglomerative (Tích tụ / Bottom-Up):**

- Bắt đầu: N cụm đơn lẻ (N lá).
- Mỗi bước: Gộp 2 cụm gần nhau nhất.
- Kết thúc: 1 siêu cụm duy nhất (Gốc).

② **Divisive (Phân tách / Top-Down):**


- Bắt đầu: 1 cụm tổng thể chứa toàn bộ dữ liệu.
- Phân rã đệ quy thành các cụm nhỏ hơn.

Ưu thế nổi bật: Không cần chọn trước số lượng cụm K khi dựng cây!



Biểu đồ Cây Dendrogram & 5 Tiêu chuẩn Liên kết (Linkage)

Giải phẫu Biểu đồ Dendrogram:



Trục tung biểu thị khoảng cách sáp nhập. **Quy tắc cắt cụm:** Cắt ngang qua nhánh dọc dài nhất không bị ngắt quãng.

5 Tiêu chuẩn Liên kết (Linkage):

- **Single Linkage:** $D(A, B) = \min d(x, y)$
(Dễ bị hiện tượng nối chuỗi - Chaining Effect).
- **Complete Linkage:** $D(A, B) = \max d(x, y)$
(Tạo cụm hình cầu đặc, tránh nối chuỗi).
- **Average Linkage:** $D(A, B) = \frac{1}{|A||B|} \sum d(x, y)$
(Cân bằng, ít nhạy cảm với ngoại lai).
- **Centroid Linkage:** $D(A, B) = \|\mu_A - \mu_B\|^2$
(Có rủi ro đảo ngược Inversion).
- **Ward's Method:** Tối thiểu hóa mức tăng tổng phương sai WCSS sau khi sáp nhập (**Tốt nhất thực tế**).

4. Density-based: Thuật toán DBSCAN


Hai siêu tham số cốt lõi:

- ϵ (Epsilon): Bán kính lân cận vùng khảo sát.
- MinPts: Số lượng mẫu tối thiểu trong bán kính ϵ .

Phân loại 3 nhóm điểm:


- **Core Point:** $|N_{\epsilon}(p)| \geq \text{MinPts}$.
- **Border Point:** $|N_{\epsilon}(p)| < \text{MinPts}$ nhưng nằm trong bán kính ϵ của một Core Point.
- **Noise Point:** Không thuộc 2 nhóm trên (gán nhãn **-1**).

Cơ chế lan truyền cụm: Liên thông mật độ thông qua các chuỗi điểm tiếp cận trực tiếp.




DBSCAN Đồ thị K-Distance & Thuật toán OPTICS

Tìm ϵ bằng Đồ thị K-Distance:




Sắp xếp khoảng cách đến láng giềng thứ $k = \text{MinPts} - 1$, điểm uốn cong (Knee) là ϵ chuẩn.

OPTICS: Khắc phục Đa mật độ:



- Tính **Core Distance** & **Reachability Distance**.
- Biểu đồ **Reachability Plot**: Thung lũng = Cụm, Đỉnh núi = Ranh giới/Nhiều.
- Trích xuất tự động qua hệ số dốc ξ .

So sánh Thực nghiệm: K-Means vs DBSCAN trên Dữ liệu Phi cầu



Nhận xét từ GeeksforGeeks: K-Means thất bại trên dữ liệu trăng khuyết (Moons), vòng tròn đồng tâm (Circles) và bị nhiễu kéo lệch tâm; trong khi DBSCAN tìm ra hình dạng phi tuyến chuẩn xác và cô lập 19 điểm nhiễu.

5. Distribution-based: Gaussian Mixture Models (GMM)


Mô hình xác suất tạo sinh (Generative Model):

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

- π_k : Trọng số thành phần ($\sum \pi_k = 1$).
- μ_k : Vector kỳ vọng (tâm cụm).
- Σ_k : Ma trận hiệp phương sai (hình dạng elip).

Phân cụm mềm (Soft Assignment):

$$\gamma_{nk} = P(z_{nk} = 1 \mid x_n) = \frac{\pi_k \mathcal{N}(x_n \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n \mid \mu_j, \Sigma_j)}$$



Thuật toán Expectation-Maximization (EM) & Ma trận Hiệp phương sai


Hai bước luân phiên của EM:

- **E-step:** Tính ma trận trách nhiệm γ_{nk} theo tham số hiện tại.
- **M-step:** Cập nhật tham số theo trung bình có trọng số:

$$\mu_k = \frac{1}{N_k} \sum \gamma_{nk} \mathbf{x}_n, \quad \pi_k = \frac{N_k}{N}$$

$$\Sigma_k = \frac{1}{N_k} \sum \gamma_{nk} (\mathbf{x}_n - \mu_k)(\mathbf{x}_n - \mu_k)^T$$

Bảo đảm toán học: Hàm Log-Likelihood luôn tăng đơn điệu sau mỗi epoch!



4 Dạng ma trận hiệp phương sai:

- **spherical:** Hình cầu, đẳng hướng.
- **diag:** Elíp song song các trục tọa độ.
- **tied:** Các cụm chia sẻ chung 1 ma trận.
- **full:** Elíp tự do mọi hướng (tổng quát).

Trường phái Thứ 5: Phân cụm Mờ (Fuzzy C-Means - FCM)

Bản chất Phân cụm Mờ (GeeksforGeeks):

- Mở rộng mềm từ K-Means của Bezdek (1981).
- Mỗi điểm thuộc về nhiều cụm với mức độ mờ $u_{ik} \in [0, 1]$ thỏa mãn $\sum_{k=1}^K u_{ik} = 1$.

Hàm mục tiêu mờ ($m > 1$ là tham số mờ):

$$J_m = \sum_{i=1}^N \sum_{k=1}^K u_{ik}^m \|x_i - \mu_k\|^2 \rightarrow \min$$

Công thức cập nhật luân phiên:

$$u_{ik} = \frac{1}{\sum_{j=1}^K \left(\frac{\|x_i - \mu_k\|}{\|x_i - \mu_j\|} \right)^{\frac{2}{m-1}}}, \quad \mu_k = \frac{\sum_{i=1}^N u_{ik}^m x_i}{\sum_{i=1}^N u_{ik}^m}$$

So sánh với K-Means & GMM:

- **Khi $m \rightarrow 1$:** FCM thoái hóa trở về K-Means tiêu chuẩn (Hard).
- **Khác biệt với GMM:** FCM không giả định phân phối Gaussian, tối ưu hóa trực tiếp trên ma trận độ thuộc mờ u_{ik} .
- **Ứng dụng tiêu biểu:** Phân đoạn ảnh MRI y tế (vùng mô não ranh giới), chấm điểm tín dụng biên.

6. Đánh giá Chất lượng Phân cụm (Clustering Metrics)

Khi KHÔNG có nhãn thực tế (Internal):

- **Silhouette Coefficient** ($s \in [-1, 1]$):

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

$a(i)$: khoảng cách nội cụm trung bình; $b(i)$: khoảng cách tới cụm gần nhất. $s > 0.5 \implies$ Tốt.

- **Davies-Bouldin Index (DBI)**: Tỷ số giữa độ phân tán nội cụm và khoảng cách liên cụm. **Càng nhỏ càng tốt.**
- **Calinski-Harabasz Index**: Tỷ số phương sai liên cụm / nội cụm. **Càng lớn càng tốt.**

Khi CÓ nhãn đối chuẩn (External):

- **Adjusted Rand Index (ARI)**: Đo tỷ lệ cặp điểm được gán cùng nhóm, khử yếu tố ngẫu nhiên ($-1 \leq \text{ARI} \leq 1$).
- **Normalized Mutual Information (NMI)**: Tương hỗ thông tin chuẩn hóa giữa nhãn thực và nhãn dự báo ($0 \leq \text{NMI} \leq 1$).

Chọn mô hình xác suất (GMM):


$$\text{BIC} = -2 \ln L + p \ln N \rightarrow \min$$

$$\text{AIC} = -2 \ln L + 2p \rightarrow \min$$

Bảng So sánh Tổng hợp 5 Trường phái Thuật toán

Tiêu chí	K-Means	Hierarchical	DBSCAN	OPTICS	GMM / FCM
Loại phân cụm	Cứng (Hard)	Cứng (Hard)	Cứng (Hard)	Cứng (Hard)	Mềm (Soft)
Cần chọn trước K?	Bắt buộc	Không	Không	Không	Bắt buộc
Hình thái cụm	Hình cầu lồi	Hình cầu / Linh hoạt	Bất kỳ (Phi tuyến)	Bất kỳ (Phi tuyến)	Hình Elip tự do
Cụm đa mật độ	Kém	Trung bình	Kém	Rất tốt	Tốt
Xử lý ngoại lai	Kém (bị kéo tâm)	Kém	Tự động lọc	Tự động lọc	Trung bình
Độ phức tạp Time	$O(N \cdot K \cdot I)$	$O(N^2 \log N)$	$O(N \log N) \rightarrow O(N^2)$	$O(N \log N) \rightarrow O(N^2)$	$O(N \cdot K \cdot I \cdot d^3)$
Độ phức tạp Space	$O(N \cdot d)$	$O(N^2)$	$O(N)$	$O(N)$	$O(N \cdot d + K \cdot d^2)$
Đầu ra trực quan	Tâm cụm, Voronoi	Dendrogram	Nhãn cụm phẳng	Reachability Plot	Elip tin cậy

Cây Quyết định Lựa chọn Thuật toán trong Thực tế



6 Ứng dụng Thực tiễn Đột phá của Phân cụm (GeeksforGeeks)

- **1. Phân khúc Thị trường & Khách hàng (Market):** Nhóm khách hàng theo mô hình RFM (Recency, Frequency, Monetary) để cá nhân hóa chiến dịch tiếp thị.
- **2. Phân cụm Tài liệu (Document Clustering):** Tự động nhóm tin tức, văn bản pháp luật bằng Cosine distance trên không gian TF-IDF/Embedding.
- **3. Phát hiện Dị thường & Gian lận (Anomaly):** DBSCAN cô lập giao dịch giả mạo tín dụng rơi vào vùng mật độ thấp (nhiều).
- **4. Phân đoạn Ảnh & Nén Ảnh (Image Segmentation):** K-Means lượng tử hóa màu (Color Quantization), giảm dung lượng lưu trữ ảnh mà giữ nguyên chất lượng.
- **5. Hệ thống Gợi ý (Recommendation Systems):** Gom nhóm người dùng tương đồng sở thích (Collaborative Filtering) để đề xuất sản phẩm/phim.
- **6. Sinh học & Phân tích Gen (Bioinformatics):** Hierarchical Clustering nhóm các gen có biểu hiện tương đồng (Gene Expression Analysis).

Thách thức & Giới hạn của Phân cụm Dữ liệu (GeeksforGeeks)

1. Xác định số lượng cụm K tối ưu:

- Vì không có nhãn đối chuẩn, việc chọn K mang tính chủ quan.
- Đòi hỏi kết hợp Elbow, Silhouette và kiến thức nghiệp vụ miền (Domain Knowledge).

2. Độ nhạy cảm với Khởi tạo & Outliers:

- K-Means dễ rơi vào cực tiểu cục bộ nếu không dùng K-Means++.
- Ngoại lai có thể làm sai lệch hoàn toàn vị trí tâm cụm.

3. Lời nguyền Số chiều (Curse of Dimensionality):

- Khi số chiều d quá lớn, khoảng cách giữa các cặp điểm đều tiến về một giá trị tương đương (Distance Concentration).
- *Giải pháp:* Cần giảm chiều bằng PCA/t-SNE trước khi gom cụm.

4. Chi phí Tính toán trên Big Data:

- Hierarchical ($O(N^2)$ bộ nhớ) bất khả thi khi $N > 20,000$.
- Cần chuyển sang Mini-Batch K-Means hoặc BIRCH.

Tổng kết & Lộ trình Thực hành Lab

Tóm tắt bài học:

- Phân cụm là công cụ khám phá cấu trúc tự nhiên mạnh mẽ nhất của Khoa học Dữ liệu.
- Không có một thuật toán duy nhất tối ưu cho mọi bài toán (*No Free Lunch Theorem*).
- Lựa chọn thuật toán phụ thuộc chặt chẽ vào:
 - Kích thước dữ liệu N (Scale).
 - Hình thái hình học của cụm (Cầu vs Phi tuyến).
 - Tỷ lệ nhiễu và ngoại lai.
 - Yêu cầu bài toán kinh doanh (cứng hay mềm).

Nội dung Thực hành trong Notebook:

1 Bài tập tính tay (Hand Calculations):

- 1 vòng lặp K-Means trên tập số liệu mẫu.
- Sáp nhập Single/Complete Linkage.
- Phân loại Core/Border/Noise trong DBSCAN.
- 1 chu kỳ E-step & M-step trong GMM.

2 Bài tập Điền khuyết Code (Fill-in-the-Blank):

- Hoàn thiện code Scikit-Learn.
- Tự động chấm điểm (Assert test).